## Klasyfikacja toksycznych komentarzy

Plan pracy

grupa: Marcin Drzewiecki, Patryk Świątek, Magdalena Szypulska

W naszym projekcie podejmiemy się wyzwania klasyfikacji toksycznych komentarzy, które zostały zaczerpnięte z forum edytorskiego anglojęzycznej Wikipedii. Na podstawie treści komentarzy stworzymy efektywny klasyfikator, który będzie przypisywał, czy dany komentarz jest obelgą, groźbą czy też zniewagą.

źródło: https://www.kaggle.com/c/jigsaw-toxic-comment-classification-challenge

Naszą pracę rozłożyliśmy na następujące etapy, przydzielając przy tym określone zadania członkom grupy:

NAZWA ZADANIA	OSOBY PRZYDZIELONE	OPIS
Przygotowania wstępne	Patryk Świątek, Magdalena Szypulska, Marcin Drzewiecki	Wybór tematu, dyskusja na temat doboru narzędzi pracy. Przygotowanie wstępnych dokumentów.
Feature extraction i wstępny preprocessing	Patryk Świątek	Przygotowanie danych tekstowych. Wydobycie z danych istotnych cech wpływających na bycie określonym typem toksycznego komentarza.
Analiza danych i dalszy preprocessing	Magdalena Szypulska	Podstawowe statystyki, wizualizacje, dalsze decyzje dotyczące obróbki danych.
Zbudowanie klasyfikatora	Patryk Świątek, Magdalena Szypulska, Marcin Drzewiecki	Zbudowanie multi- klasyfikatora. Rozważenie różnych podejść do problemu.

Testy i ewaluacja klasyfikatora	Patryk Świątek, Magdalena Szypulska, Marcin Drzewiecki	Przetestowanie klasyfikatora, ocena jego jakości za pomocą krzywych ROC, AUC itd.
Przygotowanie prezentacji	Marcin Drzewiecki	Przygotowanie prezentacji podsumowującej dotychczasową pracę.

## Szczegóły techniczne:

Język programowania:

Python 3.8

Środowisko wykonawcze:

Google Colab

Narzędzia do obróbki danych:

wektoryzowanie danych tekstowych (narzędzia z pakietu sklearn. feature\_extraction.text), skalowanie danych, PCA